

Reporte Ejecutivo — El trabajo y la voz del ciudadano colombiano

Michael Morantes | Machine Learning con PySpark y Docker | Semestre 2026-1 | Mayo 2026

1. Resumen Ejecutivo

Colombia enfrenta un problema estructural de informalidad laboral que afecta a más de la mitad de su fuerza de trabajo. Aunque este fenómeno es ampliamente documentado, pocas veces se conecta con la experiencia concreta del ciudadano cuando interactúa con el Estado. Este proyecto intenta hacer exactamente eso: partir de los microdatos de la Gran Encuesta Integrada de Hogares (GEIH) del DANE con corte a diciembre de 2025, caracterizar la informalidad laboral con técnicas de Machine Learning, y contrastar ese panorama con el tono y el contenido de las Peticiones, Quejas, Reclamos y Sugerencias (PQRS) radicadas ante la Alcaldía de Flandes (Tolima), disponibles en Datos Abiertos Colombia.

Los resultados confirman que el 57.5% de los ocupados a nivel nacional no cotizan a pensión, que un modelo de Random Forest puede predecir esa condición con un F1 de 88.65% y un AUC-ROC de 95.27%, y que el 22.0% de las PQRS analizadas expresan un tono negativo hacia la administración pública. La hipótesis que conecta estos hallazgos es que el ciudadano que más sufre la informalidad económica es, al mismo tiempo, el que más recurre al Estado con quejas y reclamos.

2. Metodología

Todo el ecosistema de procesamiento se construyó dentro de contenedores Docker usando Apache Spark (PySpark) como motor de cómputo distribuido. Esta decisión garantiza que cualquier persona con acceso al repositorio pueda reproducir los resultados exactos sin depender de una configuración local específica. El trabajo se organizó en tres bloques metodológicos que se alimentan entre sí.

El primer bloque consistió en el análisis exploratorio de la GEIH. Se unieron los módulos de Características Generales (66,559 personas) y Ocupados (29,611 registros) a través de un join interno por las llaves DIRECTORIO, SECUENCIA_P y ORDEN, obteniendo una tabla maestra de 29,126 ocupados activos. La variable objetivo se construyó siguiendo el criterio de la OIT: un trabajador es informal si no cotiza a un fondo de pensiones (P6920=2). El dataset presentó muy buena calidad: solo el ingreso laboral (INGLABO) tuvo nulos (2.0%) y no se encontraron registros duplicados por llave de identificación.

El segundo bloque aplicó aprendizaje automático sobre esos datos. Se construyó un pipeline de preparación con Imputer (mediana para ingresos faltantes), StringIndexer, OneHotEncoder, VectorAssembler y StandardScaler, produciendo un vector estandarizado de 148 dimensiones. Para el análisis no supervisado se combinó PCA con K-Means, usando el método del codo para determinar el número óptimo de grupos (K=4). Para la clasificación supervisada se entrenaron Regresión Logística y Random Forest con un split 80/20, y se afinó el Random Forest mediante validación cruzada de 3 folds explorando combinaciones de numTrees (50 o 100) y maxDepth (4 u 8).

El tercer bloque procesó el corpus de 4,614 PQRS con técnicas de NLP. Dado que el corpus no tenía etiquetas de sentimiento, se aplicó destilación de conocimiento: el modelo Transformer robertuito (pysentimiento/robertuito-sentiment-analysis, pre-entrenado en español) etiquetó automáticamente cada documento como Positivo, Negativo o Neutro. Con esas etiquetas se entrenó una Regresión Logística sobre vectores TF-IDF, lo que permitió comparar el rendimiento del enfoque clásico frente al modelo de estado del arte.

3. Resultados Clave

Una de las primeras preguntas que guió el análisis fue si la informalidad afecta a todos los trabajadores por igual. La respuesta es claramente no. La tabla a continuación muestra cómo la tasa de informalidad varía drásticamente según la posición ocupacional, pasando de cero en empleados del gobierno hasta casi la totalidad en trabajadores familiares sin remuneración. El caso más relevante en términos de volumen es el de los trabajadores por cuenta propia: con más de 12,000 personas en la muestra y una tasa del 84.8%, este grupo concentra la mayor parte del problema.

Posición ocupacional	Personas	Tasa de informalidad
Empleado de gobierno	1,520	0.0%
Obrero sector privado	12,522	32.2%
Cuenta propia	12,287	84.8%
Empleado doméstico	911	86.1%
Trab. familiar s/rem.	492	97.0%

Para profundizar en la segmentación de la fuerza laboral, se aplicó K-Means sobre el espacio reducido por PCA. El método del codo identificó cuatro grupos con perfiles socioeconómicos bien diferenciados. El cluster de menor informalidad (19.4%) agrupa a trabajadores jóvenes con ingresos altos, mientras que los dos clusters de mayor informalidad (87.3% y 90.6%) corresponden a personas de mayor edad con ingresos que apenas superan el millón de pesos. Junto a esta segmentación, la tabla de métricas muestra que el Random Forest superó a la Regresión Logística en todos los indicadores, con un AUC-ROC de 95.27% que confirma una excelente capacidad discriminante.

Cluster	N	Ing. medio COP	Informal	Métrica	Reg. Log.	Rand. Forest
Formal joven	8,521	2,916,704	19.4%	Accuracy	86.31%	88.64%
Mixto	10,781	1,605,792	59.7%	F1 ponderado	86.28%	88.65%
Cuentapropista	6,973	1,122,894	87.3%	AUC-ROC	93.88%	95.27%
Alta informal.	2,851	1,017,144	90.6%	F1 CV val.	—	89.26%

En cuanto al análisis de lenguaje natural, el corpus de 4,614 PQRS mostró el desbalance esperado en comunicaciones ciudadanas con el Estado: el 77.6% fueron clasificadas como neutras (trámites administrativos), el 22.0% como negativas (quejas directas) y apenas el 0.5% como positivas. El vocabulario del corpus tiene 13,028 términos únicos sobre 104,170 tokens, con un TTR de 0.125 que refleja alta repetición de jerga administrativa. El clasificador TF-IDF logró 87.98% de exactitud, pero al probarlo en seis casos difíciles como sarcasmo, negaciones e ironía, falló en cinco de ellos clasificando casi todo como neutro. El modelo robertuito, en cambio, identificó correctamente todos esos casos, lo que evidencia la superioridad de los Transformers para capturar matices del lenguaje natural.

4. Reflexión Integradora

Lo más interesante de este proyecto no son los modelos en sí, sino la historia que cuentan juntos. Un trabajador cuenta propia con ingreso mediano de 1,423,500 COP y 84.8% de probabilidad de no tener pensión no tiene margen para absorber errores del Estado. Cuando ese mismo ciudadano acude a la Alcaldía con un reclamo sobre el impuesto predial o el catastro, no lo hace desde una posición de comodidad: lo hace porque no tiene otra salida. Las palabras que más predicen el sentimiento negativo en las PQRS, como 'costoso' y 'fallecida', no son casuales; reflejan exactamente ese perfil de ciudadano que ya está al límite económico.

Desde el punto de vista metodológico, la combinación de PySpark para datos estructurados y un pipeline NLP escalable demuestra que este tipo de análisis puede hacerse a nivel nacional. Con datos georreferenciados de PQRS de cientos de municipios cruzados con la tasa de informalidad municipal de la GEIH, un gobierno podría anticipar dónde va a concentrarse la tensión ciudadana antes de que escale.

5. Limitaciones

La limitación más importante del proyecto es la diferencia de alcance entre las dos fuentes de datos. La GEIH es representativa de todo el territorio nacional, mientras que las PQRS provienen exclusivamente del municipio de Flandes. Esto impide establecer correlaciones causales directas entre la informalidad de un departamento específico y el volumen de quejas de ese mismo lugar.

En el componente NLP, el corpus presentaba un desbalance de clases severo: apenas 21 documentos positivos de un total de 4,614. En la práctica esto hace que los modelos funcionen como clasificadores binarios Neutro/Negativo, aunque técnicamente estén entrenados en tres clases. Adicionalmente, el patrón de no respuesta en la variable de ingresos (INGLABO), aunque bajo (2.0%), tiende a concentrarse en los extremos del espectro económico y podría sesgar sutilmente la caracterización de los clusters. Por último, la ausencia de GPU en el entorno de ejecución impidió realizar fine-tuning de robertuito para el dominio específico de trámites municipales colombianos.

6. Recomendaciones

La prueba de casos difíciles en el bloque NLP dejó claro que TF-IDF no es suficiente para producción. En un sistema real de clasificación de PQRS, donde el ciudadano usa sarcasmo, negaciones compuestas y regionalismos, la única alternativa viable es un modelo Transformer con fine-tuning sobre un subconjunto de documentos anotados manualmente para el dominio de trámites colombianos.

Para validar cuantitativamente la hipótesis integradora del proyecto, el siguiente paso natural sería ampliar el corpus de PQRS a escala nacional consumiendo las APIs de Datos Abiertos, y cruzar esa información con la tasa de informalidad por municipio estimada con la GEIH. Finalmente, extender el análisis a los doce meses del año permitiría detectar estacionalidad en la informalidad y en el tono de las quejas ciudadanas, y verificar si eventos como el ciclo electoral o el cierre fiscal impactan alguno de los dos fenómenos.
